

تشخیص عواطف توسط دستگاه‌های پوشیدنی

۲۵ تیر ۱۴۰۳

چکیده

تشخیص عواطف یکی از کاربردهای روزافزون هوش مصنوعی است. این کار می‌تواند در صنعت روانشناسی و خصوصا حوزه ترکیبی محاسبات عاطفی نقش بسیار پررنگی ایفا کند. همچنین هر روز پیشرفت بیشتری را در مورد پوشیدنی‌های هوشمند و افزایش استفاده از آنها را شاهد هستیم.


فهرست مطالب

۱	عواطف	۳
۲	مجموعه داده	۳
۱.۲	دستگاه Respiban	۴
۲.۲	ساعت Empatica E4	۴
۳.۲	پرسشنامه‌ها	۴
۴.۲	طبقه‌بندی	۶
۳	کارهای مشابه	۶
۱.۳	روش شناسی	۶
۴	پیش‌پردازش	۹
۱.۴	ساختار مجموعه داده	۹
۲.۴	تمیزسازی داده‌گان	۹
۵	روش‌های آموزش	۱۰
۱.۵	مدل BioT	۱۰
۲.۵	ساختار مدل	۱۰
۱.۲.۵	امیدینگ اولیه	۱۱
۲.۲.۵	بخش ترانسفورمر	۱۱
۳.۵	مراحل خوراندن داده به مدل	۱۱
۴.۵	استخراج ویژگی‌ها	۱۲
۶	نتایج	۱۲
۱.۶	۲ کلاسه	۱۲
۲.۶	۳ کلاسه	۱۳
۱.۲.۶	سیگنال‌های سینه‌ای	۱۳
۲.۲.۶	سیگنال‌های مچ	۱۳
۳.۲.۶	روند	۱۳

۱ عواطف

۲ مجموعه داده

مجموعه داده [1] WESAD یکی از کامل‌ترین مجموعه‌های داده برای تشخیص عواطف است. بیشترین تمرکز و استفاده از این مجموعه برای تشخیص استرس بوده‌است. با این وجود، به جز کلاس استرس و عادی، برای تشخیص کلاس‌های خوشحالی و آرامش نیز می‌توان از این داده‌ها استفاده نمود. علاوه بر آن‌ها، هر شخص پرسشنامه‌هایی نیز پر کرده که این هم می‌تواند باعث خلق مدل‌های جدیدی شود. دو دستگاه اصلی برای فراهم آوردن این داده‌ها مورد استفاده قرار گرفته‌اند: ۱) مچ‌بند Empatica E4 به بسیاری از دانشگاه‌های سراسر دنیا از آن استفاده می‌کنند [2] و ۲) دستگاه Repiban که یکی از پیشرفته‌ترین سنسورهای تحقیقاتی است که بر روی سینه نصب می‌شود [3].



شکل ۱: شکل راست: ساعت Empatica E4 را نشان می‌دهد. این ساعت به دلیل سنسورهای کامل، زیبایی و راحتی استفاده کاربرد زیادی در تحقیقات دارد. شکل چپ: دستگاه Respiban و نحوه قرارگیری آن روی سینه و محل هر یک از سنسورها را نشان می‌دهد.

۱.۲ دستگاه Respiban

این دستگاه می‌تواند ۶ عامل را اندازه‌گیری کند. فرکانس ورودی این دستگاه برای همه سنسورهایش ۷۰۰ هرتز می‌باشد. سنسورهای آن به شرح زیر است:

۱. مختصات یابی (Accelerometer)
۲. نوار قلب (Electrocardiogram)
۳. فعالیت الکتریکی پوست (Electrodermal Activity)
۴. برق‌ماهیچه‌نگار (Electromyogram)
۵. تنفس (Respiration)
۶. دما (Temperature)

۲.۲ ساعت Empatica E4

این ساعت شامل سنسورهای مختصات یابی، فشار خون^۱، دما، فعالیت الکتریکی پوست است. هر یک از این سنسورها با فرکانس متفاوتی اندازه‌گیری شده‌اند. در جدول مقدار فرکانس هر یک از سنسورها آورده شده است.

۳.۲ پرسشنامه‌ها

علاوه بر دو دستگاه گفته شده، هر یک از سوژه‌های آزمایش، پرسشنامه‌هایی را پر کردند. این پرسشنامه‌ها در جهت دریافت اطلاعات بیشتر در مورد احساسات اشخاص به کار گرفته شدند، اگرچه در هیچ‌یک از مقالات بررسی شده، محققان از این پرسشنامه‌ها استفاده‌ای نکردند. در قسمت‌های پیش‌رو این پرسشنامه‌ها را بررسی می‌کنیم:

^۱ Blood Volume Pressure

سنسور	فرکانس
ACC	۳۲
BVP	۶۴
EDA	۴
Temp	۴

PANAS

سوژه می‌بایست به ۲۶ حس در پرسشنامه، از ۱ تا ۵ امتیاز دهد. این احساسات عبارتند از: فعال، پریشانی، علاقه مند، الهام‌شده، رنجیده، گناهکار، ترسیده، دشمنی، هیجان‌زده، مغرور، کج خلق، مشتاق، شرمند، هوشیار، نگران، مصمم، متوجه، عصبی، وحشت‌زده، استرسی، خسته، خوشحال، عصبانی، آزردن و ناراحت.

STAI

در این پرسشنامه، سوژه به هر یک از سوال‌های زیر از ۱ تا ۴ نمره می‌دهد:

۱. من احساس راحتی می‌کنم
۲. من احساس نگرانی می‌کنم
۳. من عصبی هستم
۴. من ریلکس هستم
۵. من احساس دلواپسی می‌کنم
۶. من احساس رضایت می‌کنم

SAM

این تست شدت و خوب یا بد بودن احساسات را می‌سنجد. شخص دو سوال را در مقیاس ۱ تا ۹ پاسخ می‌دهد: ۱) حس من چقدر خوب است و ۲) شدت این حس چقدر است.

SSSQ

این تست که کوتاه‌شده تست استاندارد SSSQ است، در زمان‌های استرس از شرکت‌کنندگان گرفته شده است. پرسش‌شوندگان به سوال‌های زیر از ۱ تا ۵ نمره می‌دهند:

۱. من متعهد به رسیدن به اهداف عملکردی‌ام هستم
۲. من می‌خواهم در این کار موفق شوم
۳. من انگیزه برای انجام این کار را دارم
۴. من خودم را بروز می‌دهم
۵. من نگران تفکرات دیگران در مورد خودم هستم
۶. من متوجه تأثیری که روی بقیه می‌گذارم هستم

۴.۲ طبقه‌بندی

این مجموعه داده عواطف انسان های مورد بررسی را در ۴ طبقه شناسایی کرده است: (۱) حالت معمولی^۲، (۲) استرس، (۳) خوشحالی^۳ و (۴) آرامش^۴.

سوژه	ثانیه‌های مفید
۲	۲۸۸۴
۳	۲۹۳۰
۴	۲۹۶۵
۵	۳۰۰۶
۶	۲۹۸۴
۷	۲۹۸۳
۸	۳۰۰۰
۹	۲۹۸۵
۱۰	۳۰۶۸
۱۱	۳۰۱۴
۱۳	۳۰۱۶
۱۴	۳۰۱۶
۱۵	۳۰۲۲
۱۶	۳۰۰۸
۱۷	۳۰۰۲

جدول ۱: ثانیه‌های مفید هر یک از سوژه‌ها

در جدول ۱ ثانیه‌های مفید هر یک از سوژه‌ها آورده شده است. منظور از ثانیه‌های مفید، آنهایی است که کلاس‌های آنها حالت پایه، استرس، خوشحالی و یا آرامش است. در دادگان دو کلاس بی‌نام دیگر وجود دارد که آنها میبایست حذف شوند.

کلاس‌گذاری در بیشترین فرکانس ممکن (۷۰۰) صورت گرفته و برای هر یک از سنسورها برای دستیابی به کلاس موردنظر باید آن را به فرکانس آن سنسور تبدیل کنیم.

۳ کارهای مشابه

کارهای زیادی با استفاده از این مجموعه داده برای تشخیص عواطف صورت گرفته است. گرچه این دادگان در ۴ کلاس گردآوری شده، بیشتر کارها ۲ کلاسه یا ۳ کلاسه (حالت عادی، استرس و خوشحالی) هستند. همچنین از پرسشنامه‌های موجود در دادگان بهره‌جندانی برده نشده است. در جدول ۲ کارهای مشابه که از این دادگان استفاده کردند آورده شده است.

۱.۳ روش شناسی

در ادامه به بررسی روش استفاده شده در هر یک از کارهای نام برده شده می‌پردازیم:

- Introducing WESAD, a Multimodal Dataset for Wearable Stress and Affect Detection^[1]

baseline^۲
Amusement^۳
Meditated^۴

نام کار	سیگنال‌ها	پنجره	عملکرد f-1
Introducing WESAD, a Multimodal Dataset for Wearable Stress and Affect Detection[1]	Extracted features from all the signals	پنجره : ۶۰ ثانیه، قدم: ۱/۴ ثانیه	2class: 91.47, 3class: 72.51
Transformer-based Self-supervised Multimodal Representation Learning for Wearable Emotion Recognition[7]	Wrist BVP, EDA, and Temp	پنجره : ۶۰ ثانیه (۴ هرتز)، قدم: ۱/۴ ثانیه	2class: 93.69, 3class: 82.01
Affective State Recognition with Convolutional Autoencoders[8]	All the signals	پنجره: ۱ ثانیه، قدم: ۱ ثانیه	3class: 82.82
Stress Detection by Machine Learning and Wearable Sensors[5]	Manual features from all the chest signals	پنجره: ۱۰ ثانیه، قدم: ۱۰ ثانیه	2class: 83.34, 3class: 65.73
A Transformer Architecture for Stress Detection from ECG[6]	ECG	پنجره: ۳۰ ثانیه، قدم: ۱ ثانیه	2class: 83.3

جدول ۲: کارهای مشابه بر روی دادگان WESAD

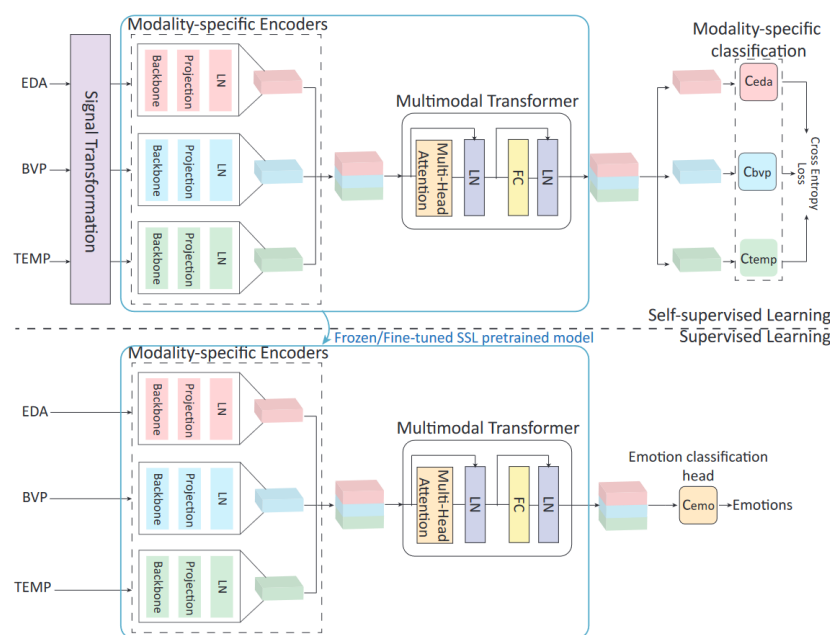
در اینجا از استخراج ویژگی‌های پیچیده‌ای استفاده گردیده‌است. برای ACC میانگین و انحراف معیار برای هر یک از ابعاد شناسایی و با هم جمع شده و علاوه بر آن نقطه اوج هر یک نیز محاسبه گردیده. از سیگنال‌های ECG و BVP میانگین و واریانس آنها و همچنین از نقاط پیک آنها ضریان قلب و از زمان های ضریان قلب، تغییرات آن^۵ به دست می‌آید. برای EDA ابتدا یک فیلتر پایین‌گذر^۶ ۵ هرتزی بر روی آن اعمال و میانگین و واریانس محاسبه می‌شود. همچنین دو بخش تونیک و فازیک این سیگنال (به نام‌های Skin Conductance Level و Skin Conductance Response) با توجه به کار [۹] استخراج شدند. بر روی سیگنال EMG ابتدا یک فیلتر بالاگذر^۷ اعمال و سپس نقاط پیک شناسایی شدند و چندین ویژگی دیگر با توجه به کار [۱۰] استخراج شدند. برای Resp ابتدا یک فیلتر میان‌گذر^۸ بر روی آن اعمال شدند. پیک‌ها شناسایی و میانگین و واریانس دم و بازدم‌ها محاسبه شدند. علاوه بر آنها نسبت دم به بازدم، حجم تنفس، نرخ تنفس و مدت زمان تنفس نیز محاسبه گردیدند. برای دما، میانگین و واریانس و بیشینه و کمینه و شیب آن محاسبه گردیده بود. برای انجام کلاسیفیکیشن، ۵ روش دسته‌بندی درخت تصمیم^۹ جنگل تصادفی^{۱۰}، k-همسایه-نزدیک^{۱۱}، تحلیل تشخیصی خطی^{۱۲} و AdaBoost استفاده شدند.

Heart Rate Variability^۵
low pass filter^۶
high pass filter^۷
band pass filter^۸
Decision Tree^۹
Random Forest^{۱۰}
K-Nearest-Neighbor^{۱۱}
Linear Discriminant Analysis^{۱۲}

- Transformer-based Self-supervised Multimodal Representation Learning : for Wearable Emotion Recognition[7]

ابتدا چندین تبدیل روی هر پنجره اتفاق می افتد:

۱. جایگشت: قسمت های مختلف پنجره جدا شده و سپس با جایگشتی دیگر به هم چسبانده می شوند.
۲. پیچ و تاب زمانی: پنجره سیگنال به n قسمت تقسیم شده و نیمی از آنها منبسط و نیمی دیگر منقبض می شوند.
۳. برش: با تقسیم پنجره به n قسمت، یکی را حذف کرده و دوباره نمونه گیری می کنیم.




شکل ۲: معماری مدل مقاله [۷]. مدل ترانسفورمر اصلی از یک توجه چندکله ای (Multi-Head Attention) و سپس نرمال ساز لایه (Layer Normalization) و سپس یک لایه کامل متصل (Fully Connected) و دوباره یک نرمال ساز لایه دیگر.

معماری مدل در شکل ۲ آورده شده است. مرحله آموزش شامل دو مرحله بوده. اول پیش آموزش آن روی دادگان PRESAGE [۱۱] انجام می شود. در مرحله دوم از انکودر مدل پیش آموزش داده شده برای کلاسیفیکیشن استفاده می شود.

- Affective State Recognition with Convolutional Autoencoders[8]

- Stress Detection by Machine Learning and Wearable Sensors[5]

در این کار بیشینه، کمینه، میانگین و انحراف معیار پنجره های ۱۰ ثانیه ای بدون اشتراک به دست آورده شده



شکل ۳: ساختار اولیه دادگان WESAD

است و سپس با بهره‌گیری از ۵ روش دسته‌بندی جنگل تصادفی، k -همسایه-نزدیک، تحلیل تشخیصی خطی، AdaBoost و ماشین بردار پشتیبان^{۱۳}، آن‌ها را دسته‌بندی کرده‌اند.

- A Transformer Architecture for Stress Detection from ECG[6]

۴ پیش‌پردازش

در بخش‌های پیش‌رو در مورد کارهای مورد نیاز برای آماده‌سازی داده‌ها برای آموزش مدل‌ها بحث می‌کنیم

۱.۴ ساختار مجموعه داده

در دادگان WESAD داده‌های تجمیع‌شده و همگام‌شده را برای هر سوژه در یک فایل pkl فراهم آورده‌اند. این فایل یک دیکشنری به صورت زیر است.

آرایه label و تمام آرایه‌های سنسورهای chest، به طول ۴،۵۴۵،۱۰۰ هستند، که همه $H \approx 700$ در طول ۶۴۹۳ ثانیه هستند. آرایه‌های ACC و BVP به ترتیب ۳۲ و ۶۴ هرتز و دو سیگنال دیگر هر دو ۴ هرتز هستند.

۲.۴ تمیزسازی دادگان

همانطور که در بالا گفته شد، برخی کلاس‌های داده بلااستفاده هستند. در قدم اول این‌ها حذف می‌شوند و تنها ثانیه‌های مفید باقی می‌مانند. سپس برای زیباسازی ساختار ذخیره داده، آن را به شکل ۴ تغییر می‌دهیم.

^{۱۳}Support Vector Machine

```

`Sx_n0.pkl`
├── label
├── chest_ACC
├── chest_ECG
├── chest_EMG
├── chest_EDA
├── chest_Temp
├── chest_Resp
├── wrist_ACC
├── wrist_BVP
├── wrist_EDA
└── wrist_TEMP

```

شکل ۴: ساختار دادگان پس از تغییر

۵ روش‌های آموزش

۱.۵ مدل BioT

مدل BioT برای کار با داده‌های EEG طراحی و ساخته شده است. اما همانطور که از نام آن پیداست (Bio Transformer) از آن می‌توان برای انواع سیگنال‌های حیاتی بهره گرفت. در شکل ۵ ساختار این مدل را مشاهده می‌کنید. در نیم تصویر بالا، ماژول توکنایز کردن سیگنال‌هاست، که با انجام دوباره نمونه‌گیری^{۱۴}، نرمال کردن، توکنایز کردن و تخت کردن^{۱۵}، آن را تبدیل به جملات می‌کند. سپس تعامل بین این جملات با استفاده از ماژول ترنسفورمر خطی (نیم‌تصویر پایین) یاد گرفته می‌شوند. این مدل به صورت با نظارت می‌تواند داده‌های مختلف کامل و ناقص را برای پیش‌آموزش و fine-tuning بپذیرد.

۲.۵ ساختار مدل

مدل از دو بخش انکودر و سر کلاسیفیکیشن^{۱۶} تشکیل شده است.

سر کلاسیفیکیشن از یک تابع فعالساز ELU^{۱۷} و یک لایه خطی تشکیل شده است که با تبدیل $xA^T + b$ انکودینگ ساخته شده را به یک وکتور با اندازه تعداد کلاس‌ها می‌برد که بیانگر احتمال این است که آن ورودی در هر کدام از آن کلاس‌ها باشد.

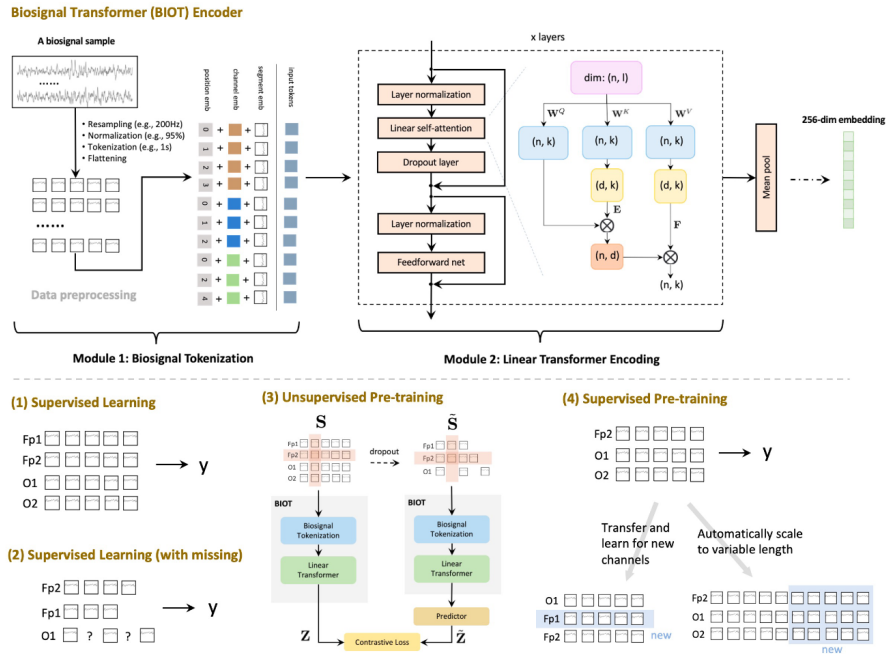
بخش انکودر نیز ابتدا یک امبدینگ اولیه ساخته و سپس آن را به ترانسفورمر داده تا برای پنجره مورد نظر یک امبدینگ نهایی بسازد. در قسمت پیش‌رو به تفصیل این دو بخش توضیح داده شده‌اند.

^{۱۴}resampling

^{۱۵}flattening

^{۱۶}Classification Head

^{۱۷}Exponential Linear Unit



شکل ۵: معماری شبکه BioT

۱.۲.۵ امبدینگ اولیه

۲.۲.۵ بخش ترانسفورمر

بخش انکودر نیز ابتدا یک امبدینگ از ورودی ساخته و سپس آن را به یک ترانسفورمر با توجه خطی^{۱۸} پاس می‌دهد. سپس خروجی ترانسفورمر که یک تانسور به ابعاد $(batch_size, combined_seqen, emb_size)$ است را با میانگین‌گیری در بعد اول تبدیل به تانسوری به ابعاد $(batch_size, emb_size)$ می‌کنیم، تا برای هر پنجره از هر سیگنال‌ها به یک امبدینگ برسیم که برگرفته از اطلاعات کل پنجره در طول زمان است.

۳.۵ مراحل خوراندن داده به مدل

برای آماده‌سازی داده خام و خوراندن آن به مدل BioT می‌بایست چندین کار انجام داد.

پس از تمیزسازی داده‌ها که در بالا گفته شد، برای هر سوژه یک فایل pickle ساخته می‌شود که مجموع ۱۵ فایل می‌شود. هر یک از این فایل‌ها یک دیکشنری به فرمت شکل ۴ است، که هر یک از آنها یک تانسور است. طول تانسور تک بعدی label ۴ برابر ثانیه‌های آن سوژه و ابعاد باقی تانسورهای سیگنال‌ها برابر (فرکانس سیگنال، تعداد کانال‌ها، ۴ برابر ثانیه‌ها) است.

علت ۴ برابر شدن ثانیه‌ها استفاده از ربع ثانیه به عنوان واحد زمانی است. همچنین تعداد کانال‌ها برای همه به جز

^{۱۸}Linear Attention Transformer

ACC برابر ۱ است.

تغییر فرکانس فرکانس مناسب برای مدل BioT برابر ۲۰۰ هرتز است. بنابراین برای هر یک از سیگنال‌ها فرکانس سیگنال را به ۲۰۰ تبدیل می‌کنیم. همچنین در کانال‌های مختلف میانگین می‌گیریم (در حقیقت این کار به جز بر ACC بر سیگنال دیگری تاثیری ندارد). در نهایت ابعاد هر یک از سیگنال‌ها به شکل (۲۰۰, ۴, ۲۰۰) برابر ثانیه‌ها) در می‌آید.

برای تغییر فرکانس دو تابع مختلف استفاده کردیم:

۱. یکی از بهترین روش‌ها برای این کار بهره‌گیری از PCA است. این روش را تنها برای سیگنال‌های سینه می‌شود استفاده کرد، چراکه PCA تنها می‌تواند ابعاد را کم کند و سیگنال‌های مجبند در بیشترین حالت ۶۴ هرتز هستند.

۲. روش دیگر استفاده از تابع resample از پکیج scipy بود. این تابع از متود فوریه برای تبدیل فرکانس یک سیگنال استفاده می‌کند. از این روش می‌توان برای همه سیگنال‌ها استفاده کرد.

نرمال‌سازی با توجه به خود مدل BioT، نرمال‌سازی به این صورت انجام می‌شود که سیگنال‌ها بر چندک ۹۵-صدم تقسیم می‌شود.

تقسیم دادگان همانند تمامی مقالات و کارهای انجام شده بر روی این دادگان، ما هم از روش LOSO استفاده می‌کنیم. بدین ترتیب به ازای هر یک از سوژه‌ها، آن را به عنوان تست و از ۱۴ تای باقی‌مانده، ۱۰ تا را به عنوان داده آموزشی و ۴ تای باقی‌مانده را به عنوان داده validation استفاده می‌کنیم.

۴.۵ استخراج ویژگی‌ها

برای تبدیل داده به فرم مناسب برای آموزش مدل‌های ماشین لرنینگ، یکی از روش‌های پرکاربرد و محبوب، استخراج ویژگی از پنجره‌های سری زمانی است. در کارهای مختلف از پنجره‌های با طول‌های متفاوت استفاده می‌کنند. برای مثال در [۴] از پنجره‌هایی به طول ۱ ثانیه، ۱۰ ثانیه [۵]، و حتی ۳۰ ثانیه [۶] استفاده کردند. در مورد آخر، یکی از علل طول زیاد پنجره به دلیل استفاده از مدل transformer و بهره‌گیری از زمینه^{۱۹} است.

۶ نتایج

۱.۶ ۲ کلاسه

برای مقایسه آن با هر یک از کارها، این مدل را با استفاده از سیگنال‌ها و پنجره‌های هر یک از کارها مقایسه می‌کنیم. در ابتدا مقایسه را ۲ کلاسه (استرس و غیر استرس) انجام می‌دهیم. در جدول ۳ نتایج با دو روش اول که پنجره‌های یکسانی داشتند مقایسه شدند. میانگین f1-score برابر ۹۱ درصد شد که دقتی نسبتاً خوب محسوب می‌شود. به دلیل محدودیت‌های محاسباتی به جای قدم‌های ربع ثانیه‌ای از قدم‌های ۶ ثانیه‌ای استفاده شد که اینگونه تعداد داده‌های آموزش به نسبت کار [۷] که بهترین کار بوده، بسیار کمتر (حدوداً ۲۵ برابر) بوده ولی با این حال دقت تنها ۲ درصد کمتر بوده که با کاهش اندازه قدم‌ها این درصد نیز بهتر خواهد شد.

^{۱۹}context

سوژه	امتیاز F-1	Accuracy
۲	0.78	0.70
۳	0.82	0.79
۴	0.90	0.88
۵	0.96	0.96
۶	0.90	0.89
۷	0.82	0.80
۸	0.84	0.80
۹	0.80	0.73
۱۰	0.96	0.96
۱۱	0.90	0.90
۱۳	0.96	0.96
۱۴	0.70	0.73
۱۵	0.96	0.96
۱۶	0.98	0.98
۱۷	0.70	0.72
مجموع	0.91	0.93

جدول ۳: نتایج BioT با پنجره ۶۰ ثانیه و قدم‌های ربع ثانیه‌ای. سیگنال‌های EDA، BVP و دمای مج استفاده شدند.

۲.۶ ۳ کلاسه

در قدم بعدی این مدل را برای ۳ کلاس تست کردیم. ۳ کلاس عبارتند از استرس، خوشحالی و عادی. در ادامه این کار را با سیگنال‌های مختلف بررسی کردیم:

۱.۲.۶ سیگنال‌های سینه‌ای

اولین آزمایش که نتایج آن در جدول ۴ آمده، را با بهره‌گیری از PCA و سیگنال‌های سینه انجام دادیم. نتایج آن به نسبت کار [۵] که از سیگنال‌های سینه بهره برده بود، حدود ۱۰٪ امتیاز F-1 بهتری داشت.

سپس آزمایش مشابهی را این بار با resample به جای PCA انجام دادیم. بدین صورت که به جای اینکه اجزای اصلی پنجره را به دست آوریم، یک نمونه پریودیک به وسیله فوریه از آن بگیریم و از آن استفاده کنیم.

در جدول ۵ که از resample استفاده شده، نتایج به مراتب بهتری گرفتیم و F-1 score حدود ۹٪ بهتر شد. این پیشرفت قابل توجه به معنای آن است که تابع بهره گرفته از فوریه resample بسیار بهتر PCA عمل می‌کند. در نهایت با سیگنال‌های سینه به تنهایی، در امتیاز F-1 به ۸۷٪ رسیدیم که از مدل تمام سینه [۵] که از مدل‌های کلاسیفیکیشن کلاسیک مانند حدود ۲۰٪ بهتر است

۲.۲.۶ سیگنال‌های مج

۳.۲.۶ روند

در شکل ۶ دقت، امتیاز Cohen و F-1 در طول روند یادگیری برای ۳ کلاس می‌باشد. حد بالای تعداد epoch ها برابر ۵۰ بوده، ولی همانطور که مشاهده می‌کنیم، ۱۲ تا از آنها قبل از این مقدار همگرا شدند و به ۵۰ نرسیدند که ۱۰ تای آنها به زیر epoch ۲۰ برای همگرایی نیاز داشتند.

سوژه	امتیاز F-1	Accuracy
۲	0.75	0.64
۳	0.54	0.57
۴	0.85	0.78
۵	0.23	0.18
۶	0.77	0.67
۷	0.54	0.59
۸	0.85	0.78
۹	0.77	0.67
۱۰	0.77	0.67
۱۱	0.77	0.67
۱۳	0.85	0.78
۱۴	0.77	0.67
۱۵	0.85	0.78
۱۶	0.85	0.81
۱۷	0.77	0.67
مجموع	0.78	0.71

جدول ۴: همانند ۳، با تفاوت اینکه در اینجا ۳ کلاس را مقایسه کردیم. در اینجا تمام سنسورهای سینه و به وسیله PCA بررسی شده‌اند.

نقطه آخر هر یک از نمودارها، آن معیار برای داده تست می‌باشد و دلیل جهش ناگهانی در آخر نمودارها همین نکته است. از بین این ۱۵ تا تنها در ۶ سوژه برای داده تست افت بدی را در معیارها شاهد بودیم که بیانگر انطباق بیش از حد^{۲۰} می‌باشد.

^{۲۰} Over fit


Accuracy	امتیاز F-1	سؤزه
0.64	0.75	۲
0.67	0.77	۳
1.0	1.0	۴
1.0	1.0	۵
0.81	0.85	۶
0.74	0.77	۷
0.74	0.69	۸
0.85	0.85	۹
0.67	0.77	۱۰
0.67	0.77	۱۱
1.0	1.0	۱۳
0.46	0.46	۱۴
0.86	0.85	۱۵
0.92	0.92	۱۶
0.63	0.69	۱۷
0.83	0.87	مجموع

جدول ۵: نتایج ۳ کلاسه با تنظیمات مشابه ۴ با تفاوت اینکه به جای استفاده از PCA، از resample استفاده شده است.

مراجع

- Schmidt, P., Reiss, A., Duerichen, R., Marberger, C., and Van Laerhoven, [۱]
K. (2018, October). Introducing wesad, a multimodal dataset for wearable
stress and affect detection. In Proceedings of the 20th ACM international
conference on multimodal interaction (pp. 400-408)
- Fauzi, M. A., Yang, B., and Yeng, P. (2022, November). Improving Stress [۲]
Detection Using Weighted Score-Level Fusion of Multiple Sensor. In Pro-
ceedings of the 7th International Conference on Sustainable Information
Engineering and Technology (pp. 65-71).
- Iqbal, T., Redon-Lurbe, P., Simpkin, A. J., Elahi, A., Ganly, S., Wijns, W., [۳]
and Shahzad, A. (2021). A sensitivity analysis of biophysiological responses
of stress for wearable sensors in connected health. IEEE Access, 9, 93567-
93579
- Bobade, P., and Vani, M. (2020, July). Stress detection with machine learn- [۴]
ing and deep learning using multimodal physiological data. In 2020 Second
International Conference on Inventive Research in Computing Applications
(ICIRCA) (pp. 51-57). IEEE.
- Garg, P., Santhosh, J., Dengel, A., and Ishimaru, S. (2021, April). Stress [۵]
detection by machine learning and wearable sensors. In 26th International
Conference on Intelligent User Interfaces-Companion (pp. 43-45).

- Behinaein, B., Bhatti, A., Rodenburg, D., Hungler, P., and Etemad, A. [१] (2021, September). A transformer architecture for stress detection from ecg. In Proceedings of the 2021 ACM International Symposium on Wearable Computers (pp. 132-134).
- Wu, Y., Daoudi, M., & Amad, A. (2023). Transformer-based self-supervised [v] multimodal representation learning for wearable emotion recognition. IEEE Transactions on Affective Computing, 15(1), 157-172.
- Rovinska, S., & Khan, N. (2022, July). Affective State Recognition with [λ] Convolutional Autoencoders. In 2022 44th Annual International Conference of the IEEE Engineering in Medicine & Biology Society (EMBC) (pp. 4664-4667). IEEE.
- Choi, J., Ahmed, B., & Gutierrez-Osuna, R. (2011). Development and eval- [η] uation of an ambulatory stress monitor based on wearable sensors. IEEE transactions on information technology in biomedicine, 16(2), 279-286.
- Wijsman, J., Grundlehner, B., Penders, J., & Hermens, H. (2013). Trapez- [ι·] ius muscle EMG as predictor of mental stress. ACM transactions on embedded computing systems (TECS), 12(4), 1-20.
- PRESAGE dataset [ιι]



شکل ۶: روند پیشرفت دقت و معیارهای دیگر در طول فرایند یادگیری. نقطه آخر این نمودارها بیانگر دقت بر روی تست است.